

Xây dựng và Triển khai Hệ thống Học máy Ứng dụng

Dự báo PM2.5 đa chân trời từ 1 đến 24 giờ tại Việt Nam

Nhóm 11

T.K. Ngọc, N.T. Nguyễn, N.M. Thắng, T.Đ. Luân, N.T. Nhân

Nhập môn Học máy - Đại học Khoa học Tự nhiên TP.HCM

Năm học 2025–2026

Thông tin nhóm và phân công công việc

Họ và tên	MSSV	Nhiệm vụ chính
Trần Kim Ngọc	23120062	Ý tưởng, crawl dữ liệu, báo cáo và slide
Nguyễn Thành Nguyên	23120063	Tiền xử lý, EDA, feature engineering
Nguyễn Mạnh Thắng	23120084	SARIMAX, temporal split, phân tích lỗi
Trần Đình Luân	23120059	LSTM đa đầu ra, learning curves
Nguyễn Thiện Nhân	23120064	XGBoost, FastAPI, React, Docker

Nội dung trình bày

1. Bài toán và mục tiêu
2. Dữ liệu và Feature Engineering
3. Ba mô hình
4. Kết quả và thảo luận
5. Ứng dụng web
6. Kết luận

1. Bài toán và mục tiêu

Từ một mốc $t + 24$ sang đường dự báo 24 giờ

- **Bản cũ:** chỉ dự báo PM2.5 tại $t + 24$.
- **Bản mới:** dự báo đồng thời $t + 1, t + 2, \dots, t + 24$.
- **Target:** PM2.5 liên tục, không phải PM2.5 hiện tại và không phải AQI.
- **Giá trị thực tiễn:** người dùng chọn đúng giờ cần đi lại hoặc hoạt động ngoài trời.


Đầu ra tại origin t

$$\hat{\mathbf{y}}_t = [\hat{y}_{t+1}, \dots, \hat{y}_{t+24}]$$


24 giá trị PM2.5, đơn vị $\mu\text{g}/\text{m}^3$.

1. Bài toán và mục tiêu

Vì sao dự báo trực tiếp PM2.5?



Phân phối PM2.5 và AQI




Độ phân tán và cực trị

Kết luận target

PM2.5 giữ biên độ vật lý và các đỉnh bụi mịn cần cảnh báo; AQI chỉ dùng tham chiếu trong EDA.

1. Bài toán và mục tiêu


Cấu trúc thời gian của PM2.5



Hồ sơ theo giờ



Chuỗi thời gian



Tự tương quan

- Tín hiệu có quán tính ngắn hạn, chu kỳ ngày và tuần.
- Đây là cơ sở cho lag, rolling, seasonal SARIMAX và chuỗi đầu vào LSTM.

2. Dữ liệu và Feature Engineering

Nguồn và phạm vi dữ liệu


- **Không khí:** Open-Meteo Air Quality API, CAMS Global cho PM2.5, PM10, O₃, NO₂, SO₂, CO.
- **Khí tượng:** Open-Meteo Historical Weather API cho nhiệt độ, độ ẩm, gió, mưa, áp suất và mây.
- **Phạm vi:** Hà Nội, TP.HCM, Đà Nẵng; dữ liệu theo giờ từ 05/08/2022 đến 09/05/2026.
- **Quy mô:** 98.907 dòng; không có city–datetime trùng hoặc khoảng thời gian phi giờ.

Giới hạn đại diện

CAMS là dữ liệu lưới khí quyển tại một điểm đại diện mỗi thành phố, không thay thế trạm mặt đất và không diễn giải ở cấp quận.

2. Dữ liệu và Feature Engineering


EDA: Phân phối các biến đầu vào



Phân phối lệch và khác thang đo cho thấy cần kiểm tra ngoại lệ, đồng thời chuẩn hóa riêng cho LSTM.

2. Dữ liệu và Feature Engineering


EDA: Ma trận tương quan



PM2.5 tương quan cao với PM10; quan hệ khí tượng yếu hơn và có thể phi tuyến.

2. Dữ liệu và Feature Engineering


EDA: Ngoại lệ PM2.5



Các đỉnh hiếm được giữ lại vì đây là các tình huống ô nhiễm cần cảnh báo, không phải lỗi để cắt bỏ tự động.

2. Dữ liệu và Feature Engineering

EDA: Mẫu hình theo thời gian



Chu kỳ theo giờ và tháng tạo cơ sở cho lag, rolling, biến sin/cos và seasonal SARIMAX.

2. Dữ liệu và Feature Engineering

Tiền xử lý và giải thích sáu class

Tiền xử lý sau EDA

- 13 giá trị O₃ âm → thiếu.
- Nội suy tuyến tính riêng theo thành phố, tối đa 6 giờ.
- Giữ các đỉnh PM2.5 hợp lệ.
- Ghép target bằng đúng timestamp cùng thành phố.

Class do nhóm tự quy ước

Good	≤ 9.0
Moderate	9.0–35.4
USG	35.4–55.4
Unhealthy	55.4–125.4
Very Unhealthy	125.4–225.4
Hazardous	> 225.4

Chỉ dùng để chẩn đoán

Class được tạo sau dự đoán để lập confusion matrix; model vẫn hồi quy PM2.5 liên tục, không dự báo AQI.

2. Dữ liệu và Feature Engineering

Feature Engineering đầy đủ

Đặc trưng nguồn và lịch sử

- 6 chất ô nhiễm, 7 biến khí tượng.
- 5 biến thời gian.
- 35 biến lịch sử PM2.5: lag 1–168 giờ; rolling 6–168 giờ; cùng giờ 7 ngày.

Đặc trưng phái sinh


- Sin/cos giờ, ngày, tháng.
- Delta và tỷ lệ rolling.
- Ventilation, humid stagnation, mưa, gió yếu.
- Wind vector, PM2.5/PM10, NO₂/CO.
- One-hot thành phố và mùa.

Đầu ra

75 cột sau mã hóa. Không feature nào sử dụng thông tin sau origin t .

2. Dữ liệu và Feature Engineering

Tạo target và chống rò rỉ



Tỷ lệ target hợp lệ từ $t + 1$ đến $t + 24$

Tập	Origin	Tỷ lệ
Train	68.829	70%
Validation	14.679	15%
Test	14.679	15%

- Chia theo `forecast_end`.
- Purge gap 24 giờ giữa các tập.
- Test bị khóa đến sau khi chọn model.

3. Ba mô hình

SARIMAX đa bước

- SARIMAX(1, 0, 0) $\times$ (1, 0, 0)₂₄, fit riêng cho từng thành phố.
- Maximum likelihood, L-BFGS tối đa 200 vòng; cả ba thành phố hội tụ.
- Dự báo đệ quy từ AR(1), seasonal AR(24) và lịch sử PM2.5.
- **Ưu điểm:** baseline thời gian rõ ràng, tham số diễn giải được.
- **Hạn chế:** giả định tuyến tính; lỗi đệ quy tích lũy ở horizon dài.

3. Ba mô hình


XGBoost Direct Multi-Horizon

- 24 XGBRegressor độc lập: model thứ h học trực tiếp $PM2.5_{t+h}$.
- 800 cây tối đa; learning rate 0,04; depth 3; min child weight 8.
- Subsample và colsample 0,85; L1 0,05; L2 3,0.
- Objective squared error, eval metric RMSE, early stopping 45 vòng.
- **Ưu điểm:** học phi tuyến và tương tác; không truyền lỗi giữa horizon.
- **Hạn chế:** 24 model riêng làm tăng thời gian huấn luyện và artifact.

3. Ba mô hình

LSTM Sequence-to-Vector

LSTM Sequence-to-Vector ? 75.928 tham số trainable



Chuỗi 72 giờ $\times$ 16 feature $\rightarrow$ 24 đầu ra; 75.928 tham số trainable.

3. Ba mô hình

Cấu hình huấn luyện LSTM


- Loss: MSE.
- Metric: RMSE và MAE.
- Adam, learning rate 10^{-3} .
- Batch 256, tối đa 60 epoch.
- Early Stopping patience 10.
- ReduceLROnPlateau patience 5.
- L2 ở Dense và Dropout.
- Không shuffle chuỗi thời gian.

Tuning

Siêu tham số được chọn bằng Validation và regularization; Test không dùng để chỉnh cấu hình.

3. Ba mô hình

Learning curves LSTM



Validation loss tốt nhất tại epoch 11; Early Stopping khôi phục trọng số tốt nhất khi Train tiếp tục giảm.

4. Kết quả và thảo luận

Giao thức chọn model mới


- ❶ Chia Validation thành 5 khối thời gian liên tiếp, mỗi khối giữ đủ ba thành phố và 24 horizon.
- ❷ Tính RMSE theo từng horizon rồi lấy trung bình trong mỗi fold.
- ❸ Chọn theo mean CV RMSE; std, worst fold và MAE là tiêu chí phụ.
- ❹ Khóa tên model trước khi mở Test.

Giới hạn phương pháp

Đây là blocked temporal validation trên candidate đã fit, không phải K-fold ngẫu nhiên và không tuyên bố refit cả ba model năm lần.

4. Kết quả và thảo luận

Độ ổn định qua năm khối Validation




XGBoost

có RMSE thấp nhất ở cả 5/5 khối; kết luận không phụ thuộc một giai đoạn Validation đơn lẻ.

4. Kết quả và thảo luận

Kết quả lựa chọn model




Model	CV RMSE	Std
XGBoost	15,80	1,32
LSTM	16,79	2,16
SARIMAX	17,69	1,65

Model được chọn

XGBoost Direct Multi-Horizon.

4. Kết quả và thảo luận

CV và Test sau khi khóa lựa chọn



Nguyên tắc

Test chỉ được mở và báo cáo sau khi XGBoost thắng trên Validation.

XGBoost trên Test


RMSE: 14,01

MAE: 8,91

Global R^2 : 0,665

4. Kết quả và thảo luận



Sai số của ba model theo horizon



Sai số tăng khi horizon dài; XGBoost có đường RMSE thấp nhất trên phần lớn dải 1–24 giờ.

4. Kết quả và thảo luận

XGBoost theo từng horizon




RMSE

tăng từ 4,01 ở $t + 1$ lên 15,96 $\mu\text{g}/\text{m}^3$ ở $t + 24$; khó nhất là $t + 16$ với 16,21.

4. Kết quả và thảo luận

Độ ổn định theo thành phố







- Hà Nội: 21,87.
- TP.HCM: 9,90.
- Đà Nẵng: 6,66.

Failure mode

Hà Nội có nhiều đỉnh và phương sai lớn; metric tổng hợp che giấu chênh lệch địa lý.

4. Kết quả và thảo luận

Learning curves XGBoost



Dấu hiệu


Khoảng cách
Train-Validation tại
best round trung bình
 $4,30 \mu\text{g}/\text{m}^3$.

Biện pháp

Early stopping chọn
vòng tốt nhất và hạn
chế overfitting ở horizon
dài.

4. Kết quả và thảo luận

Độ quan trọng đặc trưng





- PM2.5 hiện tại.
- Rolling 12h và 24h.
- City Hà Nội.
- Lag ngắn và PM10.

Không phải nhân quả

Importance chỉ phản ánh mức model sử dụng feature.

4. Kết quả và thảo luận

Khoảng conformal 90%




Test tổng hợp 92,4%. Hà Nội 89,1%, TP.HCM 94,9%, Đà Nẵng 93,2%; cần hiệu chỉnh lại khi dữ liệu drift.

Coverage

4. Kết quả và thảo luận

Dự báo trên phần cuối tập Test



Dự báo PM2.5 $t+24$ từ model đa chân trời trên phần cuối tập Test



Lát cắt $t+24$ trên 240 giờ cuối: XGBoost bám xu hướng phổ biến nhưng vẫn làm trơn một số đỉnh, đặc biệt tại Hà Nội; dải xanh là khoảng conformal 90% hiệu chỉnh từ Validation.

4. Kết quả và thảo luận


Residual và xu hướng làm tròn đỉnh



Residual tập trung gần 0 ở vùng phổ biến nhưng âm mạnh tại một số đỉnh PM2.5 cao.

4. Kết quả và thảo luận

Confusion matrix hậu xử lý



- Macro F1: 0,389.
- Good recall: 0,130.
- Very Unhealthy recall: 0,082.
- Hazardous: không có mẫu Test.

Cách đọc

Ma trận chỉ chẩn đoán model hồi quy sau khi chia dải đo nhóm quy ước.

4. Kết quả và thảo luận

Trường hợp sai lớn nhất

Hà Nội, target 25/04/2026 06:00


- Horizon: $t + 24$.
- Thực tế: $186,7 \mu\text{g}/\text{m}^3$.
- Dự báo: $50,18 \mu\text{g}/\text{m}^3$.
- Sai số tuyệt đối: $136,52 \mu\text{g}/\text{m}^3$.

Giả thuyết nguyên nhân

- Đỉnh phát thải đột ngột.
- CAMS có độ phân giải không gian hạn chế.
- Mẫu cục đoạn hiếm.
- Squared loss và cây có xu hướng làm trơn.

5. Ứng dụng web


Kiến trúc triển khai




- Chọn thành phố và horizon 1–24 giờ.
- Dự báo tự động hoặc nhập kịch bản.
- Lag và rolling lấy tự động từ lịch sử, không bắt người dùng nhập.

5. Ứng dụng web

Tổng quan và dự báo đa chân trời




Tổng quan hiện trạng




Chọn horizon và xem bản tin

5. Ứng dụng web

Kịch bản nhập tay và phân tích




Kịch bản người dùng



Phân tích xu hướng

5. Ứng dụng web

Minh bạch model và dữ liệu



- Công khai model được chọn.
- Hiển thị metric và learning curve.
- Nêu nguồn CAMS và giới hạn điểm lưới.
- API local đã kiểm thử; Docker sẵn cho Render.

6. Kết luận

Kết quả, hạn chế và hướng phát triển

Kết quả

- Dự báo PM2.5 từ $t + 1$ đến $t + 24$.
- XGBoost thắng 5/5 Validation folds.
- Test RMSE 14,01; MAE 8,91; R^2 0,665.
- Web cho chọn giờ và hai chế độ dự báo.

Hạn chế và hướng phát triển

- CAMS không phải trạm mặt đất.
- Yếu tại đỉnh hiểm và Hà Nội.
- Cần strict refit CV, weighted/quantile loss.
- Giám sát drift, tái hiệu chỉnh conformal.
- Cần xác minh URL cloud công khai trước khi nộp.

Cảm ơn thầy/cô và các bạn đã lắng nghe!

Nhóm 11 - Dự báo PM2.5 đa chân trời